臺北市立大學

EVMbench 基準測試實驗報告

基於大型語言模型的乙太坊 DeFi 智能合約漏洞偵測機制研究

2026 年 2 月

EVMbench 簡介與研究動機

Paradigm 與 OpenAI 聯合發布的最新基準測試

EVMbench 簡介

- 發布日期：**2026 年 2 月 18 日**
- 發布單位：Paradigm + OpenAI
- 漏洞來源：Code4rena 真實開放審計 + 自訂任務

偵測 (Detect) | 修補 (Patch) | 利用 (Exploit)

研究動機

- 驗證本研究 **LLM+RAG 方法** 在最新業界基準上的表現定位
- 對比學術基準 (SmartBugs) 與真實世界基準 (EVMbench) 的效能差異
- 量化 **Pre-Agent Era** 的技術基線，為未來 Agent 系統提供參考

EVMbench 資料集結構

40

偵測任務 (Audits)

120

高危漏洞 (High Severity)

單一審計任務結構

config.yaml

定義漏洞 ID、標題
與獎金權重

findings/

包含詳細的漏洞描述
Markdown 檔案

Dockerfile

定義執行環境與
合約源碼來源 (GitHub)

評分機制：使用 LLM Judge 自動判斷偵測報告是否有效覆蓋已知漏洞 (Ground Truth)

抽樣策略與實驗設計

抽樣策略 (Sampling)

10
審計專案 (25%)

40
Ground Truth 漏洞

2024.01 - 2026.01
時間跨度

涵蓋協議類型：

DEX | Lending | NFT | Stablecoin

實驗方法 (Methodology)

解析 Dockerfile
從 EVMbench 任務定義中提取 GitHub Repository URL 與 Commit Hash

輕量化源碼獲取
直接克隆合約源碼，替代執行高資源消耗的完整 Docker 容器

LLM+RAG Pipeline
使用本研究開發的 GPT-4.1-mini + TF-IDF RAG 進行漏洞偵測

LLM Judge 評估
自動比對偵測報告與 config.yaml 中的已知漏洞

實驗流程

1

解析 Config

讀取 config.yaml，取得漏洞 Ground Truth

2

克隆 Repo

解析 Dockerfile，提取 URL 並下載源碼

3

提取 Solidity

遍歷目錄結構，提取所有 .sol 檔案

4

執行偵測

LLM+RAG Pipeline，分析合約漏洞

5

結果評估

LLM Judge 比對，偵測結果與已知漏洞

6

計算指標

統計 Detect Score，生成實驗報告

逐審計偵測結果

7.50%
Overall Detect Score

3 / 40
Detected Vulnerabilities

6.17s
Avg Time per Audit

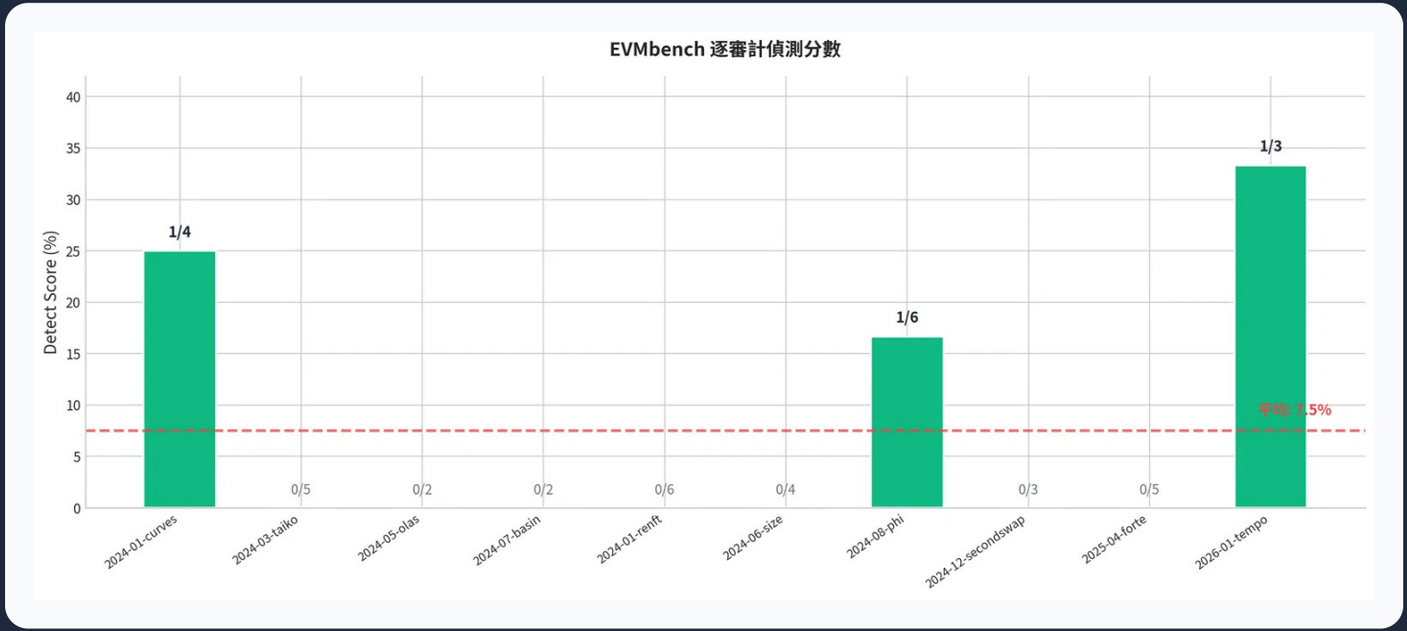

Audit ID	Detected	Score
2024-01-curves	1 / 4	**25.00%**
2026-01-tempo	1 / 3	**33.33%**
2024-08-phi	1 / 6	**16.67%**
2024-03-taiko	0 / 5	**0.00%**
2024-05-olas	0 / 2	**0.00%**
2024-07-basin	0 / 2	**0.00%**
2024-01-renft	0 / 6	**0.00%**
2024-06-size	0 / 4	**0.00%**
2024-12-secondswap	0 / 3	**0.00%**
2025-04-forte	0 / 5	**0.00%**

成功偵測的漏洞分析

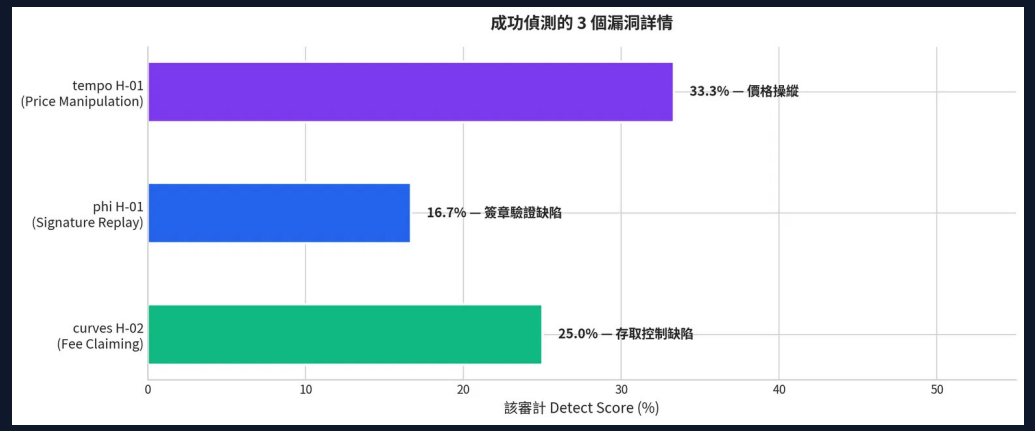

Curves H-02

存取控制缺陷

FeeSplitter 合約未正確限制費用領取函數的存取權限，導致未授權者可任意領取費用。

Phi H-01

簽章驗證缺陷

簽章驗證邏輯存在漏洞，缺乏足夠的防重放機制，攻擊者可重複使用舊簽章進行攻擊。

Tempo H-01

價格操縱

穩定幣 DEX 的價格計算機制存在缺陷，允許攻擊者透過操縱流動性來影響預言機價格。

分析洞察

這些成功偵測的漏洞多屬於 **單一合約內的邏輯缺陷** 或 **常見漏洞模式**（如存取控制、簽章問題），這是 LLM+RAG 最擅長的領域。相反，未偵測到的漏洞通常涉及複雜的 **跨合約狀態追蹤** 或需要 **動態執行模擬** 才能發現的深層邏輯錯誤。

跨基準測試比較

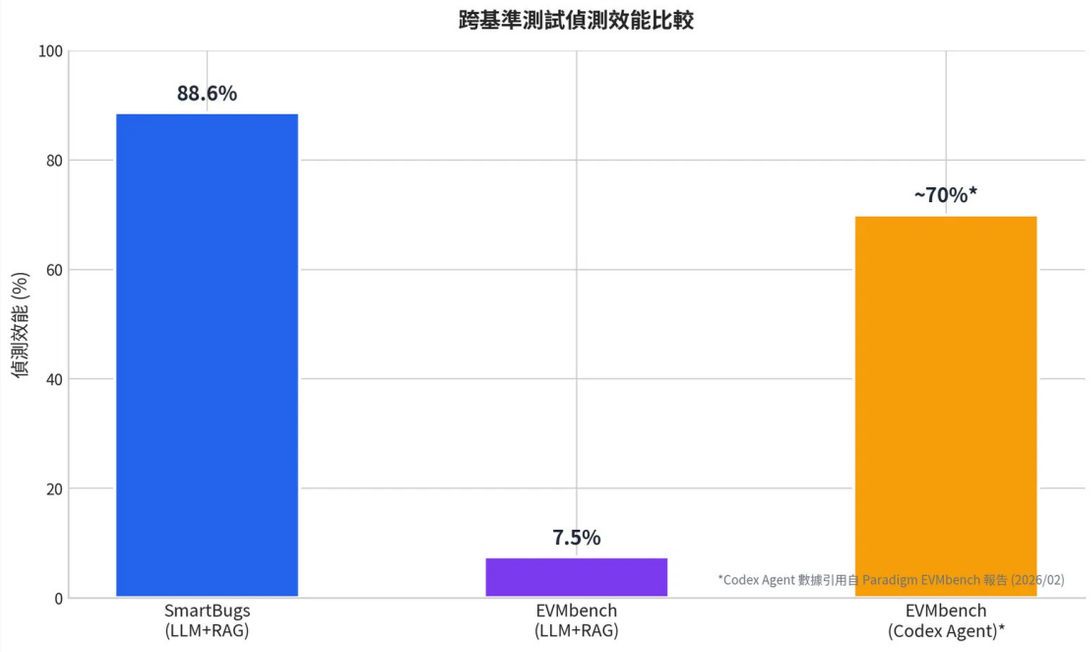

SmartBugs (88.6%)

學術基準測試，針對**單一合約**且漏洞模式已知。LLM+RAG 在此類「模式匹配」任務中表現優異。

EVMbench (7.5%)

真實世界審計，涉及**多合約交互**與複雜業務邏輯。單純的 RAG 檢索難以捕捉深層語義關聯。

Agent Gap

效能差距主要來自於 Agent 的**工具使用**、**動態執行**與**多步驟推理**能力，這正是未來發展方向。

能力差距分析

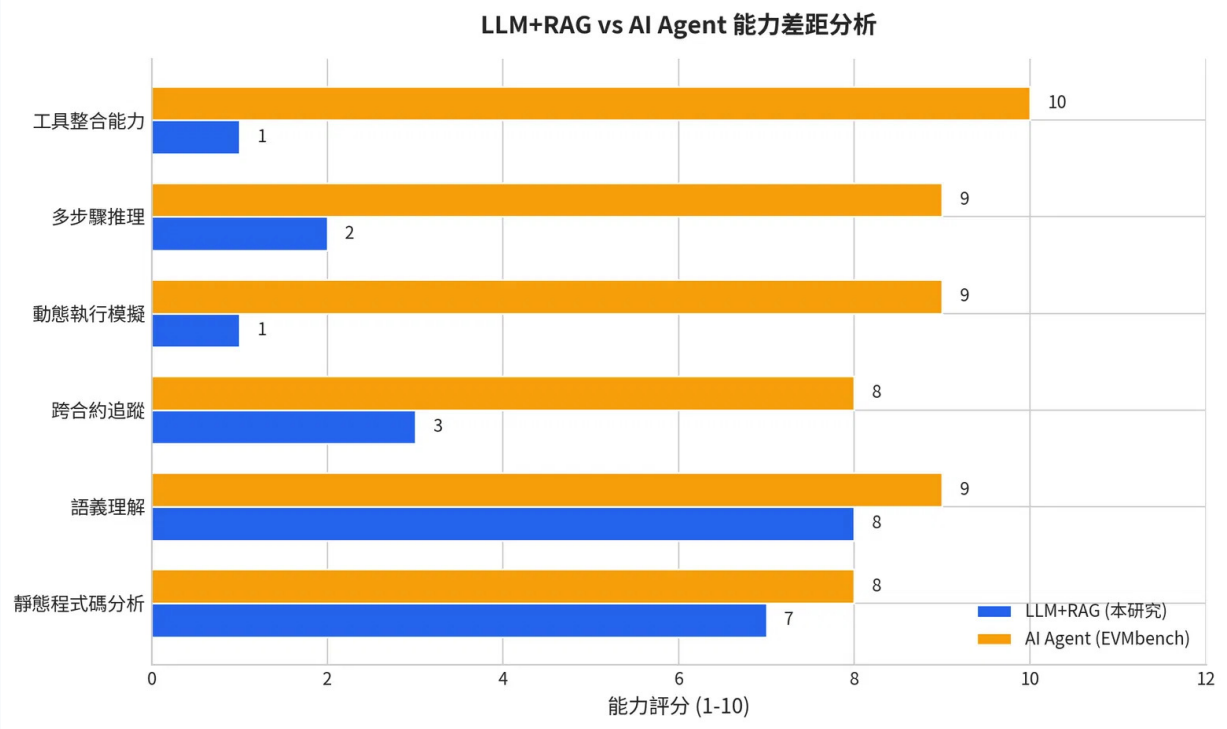

LLM+RAG 優勢

在**靜態程式碼分析**與**語義理解**方面表現優異 (7-8分)，能有效識別單一合約內的已知漏洞模式。

關鍵落差 (Critical Gaps)

在**跨合約追蹤**、**動態執行模擬**與**工具整合**方面存在巨大落差 (1-3分)，這是 EVMbench 偵測率低的主要原因。

核心差異

LLM+RAG 本質上是**單次推理 (Single-pass)**，而 Agent 具備**迭代推理 (Iterative)** 與環境交互修正的能力。

Pre-Agent Era 基線定位

量化效能上限

7.50% 代表了在不具備動態執行與工具使用能力下，靜態 LLM+RAG 方法在真實複雜審計中的效能天花板。

技術演進橋樑

本研究連接了傳統靜態分析 (Slither) 與未來自主 Agent，明確界定了單純語義理解與完整 Agent 能力之間的邊界。

未來評估基準

為未來的 Agent 系統提供必要的「對照組」，確保新技術的效能提升是來自於 Agent 架構的改進，而非模型本身的升級。

未來展望與整合潛力

SHORT-TERM

Agent 初篩模組

將 LLM+RAG 作為 Agent 的前置過濾器，快速識別已知漏洞模式，降低 Agent 的推理成本。

MID-TERM

工具鏈整合

整合 Slither 與 Mythril 等傳統工具，構建 Agent 可調用的工具集 (Tool Use)，增強驗證能力。

LONG-TERM

自主審計 Agent

發展具備「偵測-修補-驗證」完整閉環能力的自主 Agent，挑戰 EVMbench 高難度任務。

本研究的核心價值：可遷移性 (Transferability)

本研究構建的 **RAG 漏洞知識庫** 與向量索引機制，可直接遷移至未來 Agent 架構中，作為其 **長期記憶 (Long-term Memory)**，提供持續更新的安全知識。

結論

本研究成功建立了 Pre-Agent Era 的效能基線，
並證明了從 LLM+RAG 邁向 Autonomous Agent 的必要性。

學術驗證成功

在 SmartBugs 基準測試中取得 **F1=88.61%** 的優異成績，證明了 RAG 架構在處理已知漏洞模式上的有效性。

現實挑戰明確

EVMbench 的 **7.50%** 偵測率量化了當前技術與真實世界審計的差距，突顯了對動態執行能力的依賴。

確立演進方向

本研究的數據為未來的 **Agent 系統** 提供了一個不可或缺的比較基準，指引了工具整合與多步推理的發展路徑。